

УДК [УДК 004.9:331.5]

Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук
Основная образовательная программа
«Прикладная математика и информатика»

ОТЧЕТ ОБ ИССЛЕДОВАТЕЛЬСКОМ ПРОЕКТЕ НА ТЕМУ

**«АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ
YANDEX DATALENS: ИССЛЕДОВАНИЕ НА ОСНОВЕ ЕЖЕГОДНОГО
ОПРОСА РАЗРАБОТЧИКОВ STACK OVERFLOW 2024 ГОДА»**

Выполнил студент группы БПМИ 2411, 2 курса,
Елисеев Павел Алексеевич

Руководитель:
Доцент, Базовая кафедра Т-Банка
Иванов Андрей Александрович

Москва 2026

Аннотация

В работе планируется выполнить анализ результатов Stack Overflow Developer Survey 2024 и выявить факторы, связанные с уровнем совокупного дохода разработчиков (технологический стек, опыт и география). На основе подготовленных датасетов будут построены интерактивные визуализации и дашборд в Yandex DataLens для сравнения технологий и компенсаций.

Ключевые слова: Stack Overflow, Stack Overflow Developer Survey 2024, анализ данных, визуализация данных, Yandex DataLens, рынок труда в IT

Содержание

1	Основные термины и определения	4
2	Введение	7
2.1	Цель	7
2.2	Объект исследования	7
2.3	Предмет исследования	7
2.4	Методы исследования	8
2.5	Задачи	9
2.6	Актуальность работы	10
2.7	План работы	11
3	Описательный анализ набора данных	12
3.1	Общая характеристика набора данных	12
3.2	Пропуски в данных	13
3.3	География респондентов	13
3.4	Социально-демографический профиль респондентов	14
3.4.1	Тип респондента и возраст	14
3.4.2	Образование и занятость	17
3.4.3	Тип разработчика и отрасль	17
3.4.4	Опыт работы	18
3.5	Технологический ландшафт	19
3.5.1	Языки программирования	19
3.5.2	Базы данных	20
3.5.3	AI-инструменты	21
3.6	Анализ дохода	21
3.6.1	Общее распределение	21
3.6.2	Проверка закона Бенфорда	22
3.6.3	Доход по странам	26

3.6.4	Доход по опыту работы	27
3.6.5	Доход по технологиям	27
3.6.6	Совместный анализ популярности и дохода	28
3.7	Предварительная обработка данных	30
3.8	Концепция дашборда (wireframe)	32
4	Обзор источников	33
4.1	Методологические особенности набора данных	33
4.2	Академические исследования и аналитика на основе опроса	34
5	Заключение	35
5.1	Описание выполненных задач	35
5.2	Описание структуры Git-репозитория	36
5.3	Описание интерактивной визуализации	37
5.4	Ответ на основной вопрос работы	38
5.5	Ограничения работы	39
6	Описание применения генеративной модели	41

1 Основные термины и определения

1 **Stack Overflow** – это крупнейшее онлайн-сообщество и веб-сайт вопросов и ответов для профессиональных программистов и энтузиастов. Платформа служит открытой базой знаний, где пользователи могут обмениваться технической экспертизой, используя систему голосования и репутации для валидации решений и обеспечения качества контента [1].

2 **Yandex DataLens** – это инструмент бизнес-аналитики (Business Intelligence) и визуализации данных, позволяющий создавать аналитические панели (дашборды) и диаграммы посредством прямого подключения к различным источникам данных (таким как ClickHouse, PostgreSQL, CSV-файлы и API сторонних сервисов) без необходимости их предварительной миграции в единое хранилище, а также предоставляющий функционал для семантического моделирования данных на уровне датасетов [2].

3 **Stack Overflow Annual Developer Survey** – это ежегодное исследование, проводимое платформой Stack Overflow с целью систематического сбора и анализа данных о профессиональной и образовательной деятельности, используемых технологиях, инструментах, практиках разработки программного обеспечения и карьерных установках глобального сообщества разработчиков и смежных технических специалистов [3].

- 4 **Выбросы (Outliers)** – это экстремальные значения в наборе данных, которые существенно отличаются от большинства других наблюдений. В контексте анализа зарплат выбросами могут быть как ошибочно введенные данные (слишком низкие или высокие), так и реальные, но нетипичные доходы, способные исказить средние показатели.
- 5 **Разведочный анализ данных (EDA)** – это подход к анализу наборов данных с целью обобщения их основных характеристик, часто с использованием методов визуализации. EDA помогает понять структуру данных, выявить пропуски, аномалии и проверить гипотезы перед применением сложных моделей.
- 6 **Медиана** – это статистический показатель, делящий упорядоченный набор данных на две равные части. В отличие от среднего арифметического, медиана устойчива к выбросам, поэтому она является стандартом для оценки уровня заработных плат в индустрии.
- 7 **Агрегация данных** – это процесс объединения или группировки исходных данных по определенным признакам (например, группировка разработчиков по странам или языкам программирования) для вычисления сводных показателей, таких как количество, сумма или среднее значение.
- 8 **Мульти-ответы (Multiple Response)** – это тип данных, возникающий, когда респондент может выбрать несколько вариантов ответа на один вопрос (например, «Какие языки программирования вы используете?»). Для корректного анализа такие данные требуют процедуры разделения, чтобы учитывать каждый выбранный вариант отдельно.
- 9 **Дашборд (Dashboard)** – интерактивная панель Yandex DataLens, собирающая на одном экране несколько чартов, таблиц и селекторов

для совместного просмотра [2].

- 10 **Селектор (Selector)** – элемент управления дашбордом в Yandex DataLens, фильтрующий данные по значению выбранного поля; может быть связан с несколькими чартами одновременно [2].
- 11 **Датасет (Dataset)** – в Yandex DataLens слой семантической модели поверх источника, задающий поля, их типы и вычисляемые показатели для построения чартов [2].
- 12 **Вайрфрейм (Wireframe)** – схематичный эскиз интерфейса, фиксирующий состав и расположение элементов без цветов и оформления; применяется при проектировании дашборда.
- 13 **Тепловая карта (Heatmap)** – визуализация матрицы значений, где величина в каждой ячейке кодируется цветом; служит для сравнения по двум категориальным осям.
- 14 **Картограмма (хороплет, Choropleth)** – карта, на которой территориальные единицы закрашены цветом по значению показателя.
- 15 **Перцентиль** – значение, ниже которого лежит заданный процент наблюдений выборки; например, 95-й перцентиль отделяет 95% наименьших значений от 5% наибольших.
- 16 **Эмпирическая функция распределения (ECDF)** – ступенчатая функция, дающая для каждого x долю наблюдений выборки, не превышающих x .
- 17 **Закон Бенфорда** – эмпирическая закономерность: в данных, охватывающих несколько порядков, меньшие первые значащие цифры встречаются чаще; отклонение указывает на искусственное искажение данных [16].

2 Введение

Stack Overflow (SO) - одна из крупнейших платформ вопросов и ответов для разработчиков, запущенная в 2008 году. Благодаря системе голосования и репутации она сформировала обширную доверительную базу технических знаний. Сам же ежегодный Stack Overflow Developer Survey предоставляет открытые данные ситуации на рынке разработчиков, в частности об используемых ими технологиях, опыте, географии и доходах, что делает его удобным источником для анализа факторов, связанных с рынком труда.

2.1 Цель

Цель работы заключается в выявлении ключевых факторов ценообразования на глобальном рынке труда в IT-сфере на основе анализа результатов ежегодного опроса разработчиков Stack Overflow 2024 года для определения рыночной стоимости актуальных комбинаций технологий программирования.

2.2 Объект исследования

Глобальный рынок труда специалистов в сфере информационных технологий, охарактеризованный массивом данных ежегодного анкетирования сообщества Stack Overflow, по материалам из [4].

2.3 Предмет исследования

Зависимость уровня совокупного дохода (включая годовой базовый оклад и дополнительные компоненты вознаграждения, отражённые в вопросах о доходе в Stack Overflow Annual Developer Survey 2024) разработчиков от набора профессиональных компетенций (технологического стека), опыта

работы и географических факторов, а также методы визуализации этих зависимостей.

2.4 Методы исследования

- Программирование на языке Python для предварительной обработки, очистки и структурирования данных, с использованием библиотек:
 - **pandas** — для манипуляции табличными данными и разделения мульти-ответов [10];
 - **NumPy** — для математических операций и работы с массивами [11].
- Визуализация данных: статические графики разведочного анализа строились средствами **Matplotlib** [12], интерактивный дашборд — в **Yandex DataLens** [2], отдельные картограммы — с помощью сервиса **Datawrapper** [15].
- Проектирование структуры интерактивного дашборда методом вайр-фрейминга с последующей реализацией в Yandex DataLens.
- Обзор академических источников, технической документации и результатов отраслевых исследований, таких как [4].

2.5 Задачи

Задачи проекта разделяются на две части: исследовательскую и программную, а именно:

- Исследовательская часть
 - Провести описательный анализ набора данных из [4], а именно:
 - * описать социально-демографический профиль респондентов (география, опыт, роли)
 - * описать технологический ландшафт и тренды (языки, инструменты ИИ, базы данных)
 - * проанализировать структуру данных (распределение зарплат, пропуски, выбросы)
 - Провести обзор источников, использующих рассматриваемый набор данных.
 - Спроектировать структуру интерактивного дашборда методом вайрфрейминга и определить его целевую аудиторию.
- Программная часть
 - Скорректировать набор данных Stack Overflow Annual Developer Survey 2024 с помощью Python: провести очистку от выбросов, обработать пропущенные значения и выполнить нормализацию полей с множественным выбором.
 - Провести расчёт агрегированных показателей, описывающих зависимость медианного уровня совокупного дохода от используемого технологического стека, опыта работы и географической локации респондентов.

- Подготовить и экспортировать структурированные таблицы (датасеты) для последующей загрузки и визуализации в BI-системе Yandex DataLens.
- Построить в Yandex DataLens интерактивные визуализации и дашборд, позволяющие фильтровать данные и сравнивать востребованность технологий и уровни компенсаций в различных профессиональных сегментах IT-рынка.
- Пройти онлайн-курс «DataLens: анализ и визуализация данных» от Яндекс Практикума и получить сертификат.

2.6 Актуальность работы

Актуальность работы обусловлена быстрым обновлением технологического стека в IT-индустрии: состав востребованных языков, фреймворков и инструментов меняется в течение нескольких лет. Наглядный пример — AI-инструменты разработки: соответствующая категория вопросов отсутствовала в ранних выпусках опроса Stack Overflow (в частности, 2016 года [6]), тогда как по данным 2024 года их используют уже 61,8% респондентов [4].

Открытые данные Stack Overflow Annual Developer Survey 2024 позволяют количественно описать тенденции, наблюдаемые в выборке опроса, и сопоставить уровни совокупного дохода с используемым технологическим стеком, опытом работы и географией. Представление этих зависимостей в виде интерактивного дашборда делает их доступными для самостоятельного анализа и может быть полезно специалистам при выборе технологий для изучения и направления профессионального развития.

2.7 План работы

Таблица 2.1: Таблица с планом работы

Этап / Задача	Начало	Конец
Обзор литературы и анализ предметной области	10.11.25	30.11.25
Разведочный анализ данных (EDA), описание структуры выборки и проектирование дашборда (вайрфрейм)	01.12.25	20.12.25
Очистка данных (Python): обработка выбросов и пропусков	15.01.26	25.01.26
Нормализация мульти-ответов и расчёт агрегированных метрик	26.01.26	31.01.26
Подготовка и экспорт структурированных датасетов для BI	01.02.26	04.02.26
Настройка модели данных в Yandex DataLens	05.03.26	07.04.26
Создание визуализаций: распределение зарплат и технологий	08.03.26	15.03.26
Компоновка интерактивного дашборда и добавление фильтров	16.03.26	20.03.26
Интерпретация результатов и оформление заключения	05.05.26	12.05.26
Прохождение онлайн-курса и получение сертификата	20.10.25	25.12.25
Оформление репозитория проекта (Readme, структура кода)	16.05.26	25.05.26

3 Описательный анализ набора данных

Исходный набор данных Stack Overflow Annual Developer Survey 2024 [4] представляет собой CSV-файл, содержащий ответы респондентов на вопросы о профессиональной деятельности, используемых технологиях, уровне дохода и демографических характеристиках. В данном разделе проводится разведочный анализ данных (EDA) с целью описания структуры выборки, выявления закономерностей и подготовки данных к дальнейшей визуализации.

3.1 Общая характеристика набора данных

Набор данных содержит **65 437 записей** (респондентов) и **114 колонок** (переменных). Колонки можно разделить на несколько тематических групп:

- **Демографические данные:** возраст (`Age`), страна (`Country`), уровень образования (`EdLevel`).
- **Профессиональный профиль:** статус занятости (`Employment`), тип разработчика (`DevType`), опыт в годах (`YearsCode`, `YearsCodePro`, `WorkExp`), формат работы (`RemoteWork`), размер компании (`OrgSize`), отрасль (`Industry`).
- **Технологический стек (мульти-ответы):** языки программирования (`LanguageHaveWorkedWith`), базы данных (`DatabaseHaveWorkedWith`), веб-фреймворки (`WebframeHaveWorkedWith`), платформы (`PlatformHaveWorkedWith`), встроенные системы (`EmbeddedHaveWorkedWith`), а также аналогичные колонки с суффиксом `WantToWorkWith`.
- **AI-инструменты и мнения:** использование AI-инструментов (`AISelect`), отношение к AI (`AISelect`), восприятие угрозы (`AIThreat`).

- **Доход:** исходное значение компенсации (`CompTotal`) и приведённое к USD в годовом выражении (`ConvertedCompYearly`).

3.2 Пропуски в данных

Больше всего пропусков в вопросах о прогнозе интеграции AI: в колонке `AINextMuch less integrated` не заполнено 98,25% значений, в `AINextLess integrated` — 96,4%. Причина в ветвлении опросника: эти вопросы показывались только тем, кто определённым образом ответил на предыдущие вопросы об AI.

Для анализа критичны пропуски в `ConvertedCompYearly`: здесь отсутствует **42 002 значения** (64,19%) — доход указали лишь 23 435 респондентов (35,8%). Все последующие оценки дохода строятся на этой подвыборке.

Высокий процент пропусков (66%) есть и в колонке встроенных технологий `EmbeddedHaveWorkedWith` — её заполняли преимущественно узкие специалисты.

3.3 География респондентов

В опросе участвовали респонденты более чем из 180 стран, однако выборка заметно смещена в сторону англоязычных и европейских стран: `Stack Overflow` — преимущественно англоязычная платформа [5]. Двадцать стран с наибольшим числом ответов показаны на Рисунке 3.1.

Лидером по числу ответов является США (11 095 респондентов), за которыми следуют Германия (4 947), Индия (4 231) и Великобритания (3 224). Россия представлена 925 респондентами и занимает 15-е место в рейтинге. Украина находится на 5-м месте (2 672 респондента), что может объясняться значительным размером IT-сектора в данной стране.




Рис. 3.1: Топ-20 стран по количеству респондентов

3.4 Социально-демографический профиль респондентов

3.4.1 Тип респондента и возраст

Большинство респондентов (50 207 из 65 437, то есть 76,7%) являются профессиональными разработчиками. Ещё 6 511 (10%) пишут код в рамках работы или учёбы, но не являются разработчиками по основной специальности. Оставшиеся 13% включают студентов, хобби-разработчиков и бывших разработчиков (Рисунок 3.2).

Возрастная структура выборки: наибольшая группа — 25–34 года (23 911 чел., 36,5%), далее 35–44 года (14 942 чел., 22,8%) и 18–24 года (14 098 чел., 21,5%). Таким образом, более 80% респондентов находятся в возрасте от 18 до 44 лет. Однако после 35 лет доля разработчиков резко снижается: категории 45–54, 55–64 и 65+ суммарно дают лишь около 15% выборки. Этот феномен известен в литературе как «Is 40 the new 60?» [13] и отражает смещение ИТ-индустрии в сторону более молодых специалистов и/или




Рис. 3.2: Распределение респондентов по типу деятельности

переход опытных разработчиков в управленческие роли.

Для наглядного сопоставления возрастная структура профессиональных разработчиков (`MainBranch = "I am a developer by profession"`) из Stack Overflow Annual Developer Survey 2024 представлена совместно с тремя сравнительными видами экономической деятельности по данным Росстата [14]. Источник сравнительных данных — таблица 2.32 «Структура занятых по возрастным группам и видам экономической деятельности в 2023 г.». Возрастные бины SO (<18 , 18–24, 25–34, 35–44, 45–54, 55–64, 65+) были переведены в бины Росстата (15–19, 20–29, 30–39, 40–49, 50–59, 60–69, 70+) с помощью пропорционального распределения по длине возрастного интервала.

На Рисунке 3.3 слева показаны профессиональные разработчики (красный) на фоне занятых в области информации и связи (светло-серый), справа — занятые в области образования (светло-серый) и в здравоохранении и социальных услугах (тёмно-серый).

Куда исчезают профессиональные разработчики после 30?




Рис. 3.3: Сравнительное возрастное распределение: профессиональные разработчики на фоне других видов экономической деятельности (по мотивам визуализации «Is 40 the new 60?»)

Различие крайне выразительно. У разработчиков модальная возрастная группа — 30–39 лет, а суммарная доля возрастов 20–39 составляет около двух третей выборки. В то же время у работников образования и здравоохранения модальные группы находятся в диапазоне 40–59 лет (по 25–28% в каждой), а доля занятых 20–39 лет — лишь около 37%. Даже в более широкой категории «Деятельность в области информации и связи», куда входят не только разработчики, но и сетевые инженеры, системные администраторы и другие ИКТ-специальности, пик приходится на 30–39 лет, а возрастной профиль по сравнению с разработчиками сдвинут вправо примерно на одно десятилетие. Это свидетельствует о том, что среди ИКТ-отрасли именно разработка программного обеспечения представляет собой наиболее «молодой» сегмент.

3.4.2 Образование и занятость

Степень бакалавра имеют 24 942 респондента (41%), магистерскую степень — 15 557 (25,6%). Неоконченное высшее образование у 7 651 чел. (12,6%), среднее образование — у 5 793 чел. (Рисунок 3.4).

По типу занятости доминируют штатные сотрудники на полную ставку (39 041 чел.). Фрилансеры и независимые подрядчики составляют 4 846 чел., студенты — 4 709 чел. Формат работы распределён следующим образом: гибридный — 23 015 (42%), полностью удалённый — 20 831 (38%), офисный — 10 960 (20%).

3.4.3 Тип разработчика и отрасль

Наиболее распространённая роль — full-stack разработчик (18 260 чел.), далее back-end (9 928) и front-end (3 349). Среди отраслей лидирует Software Development (11 918), за ней Fintech (1 641) и Internet/Telecom (1 629). Распределение типов разработчиков представлено на Рисунке 3.5.




Рис. 3.4: Распределение респондентов по уровню образования




Рис. 3.5: Топ-15 типов разработчиков

3.4.4 Опыт работы

Медианный общий стаж программирования (`YearsCode`) составляет **11 лет** (среднее — 14,2), а медианный профессиональный стаж (`YearsCodePro`) — **8 лет** (среднее — 10,7). Распределения обоих показателей имеют правосто-

ронную асимметрию (Рисунки 3.6 и 3.7).



Рис. 3.6: Распределение общего стажа программирования (YearsCode)



Рис. 3.7: Распределение профессионального стажа (YearsCodePro)

3.5 Технологический ландшафт

3.5.1 Языки программирования

Наиболее используемым языком является JavaScript (37 492 респондента), за которым следуют HTML/CSS (31 816), Python (30 719) и SQL (30 682). TypeScript занимает 5-е место (23 150), что отражает рост его популярности в последние годы. Среди компилируемых языков лидируют Java (18 239), C# (16 318), C++ (13 827) и C (12 184). Rust набирает популярность — 7 559 респондентов (Рисунок 3.8).




Рис. 3.8: Топ-15 языков программирования (используемых в работе)

3.5.2 Базы данных

Среди баз данных лидирует PostgreSQL, далее MySQL, SQLite и Microsoft SQL Server. Полное распределение представлено на Рисунке 3.9.




Рис. 3.9: Топ-15 баз данных (используемых в работе)

3.5.3 AI-инструменты

Использование AI-инструментов в разработке получило широкое распространение: 37 662 респондента (61,8%) уже используют AI-инструменты, ещё 8 408 (13,8%) планируют начать. Отношение к AI преимущественно положительное: 22 167 оценивают его благоприятно, 10 848 — очень благоприятно. При этом лишь 5 388 (12,1%) воспринимают AI как угрозу для своей работы (Рисунок 3.10).




Рис. 3.10: Топ-15 AI-инструментов, используемых в разработке

3.6 Анализ дохода

3.6.1 Общее распределение

Переменная `ConvertedCompYearly` содержит значения совокупного годового дохода, приведённые к USD. Описательная статистика до фильтрации выбросов: среднее значение — \$86 155, медиана — \$65 000, стандартное отклонение — \$186 757. Минимальное значение (\$1) и максимальное

(\$16 256 603) указывают на присутствие выбросов. Детальное распределение зарплат представлено на Рисунке 3.11.

Феномен «зубцов» на гистограмме. На Рисунке 3.11(а, б) гистограмма имеет выраженно «зубчатую» форму: вместо плавной унимодальной кривой видны регулярные пики и провалы. Пики сосредоточены на «круглых» значениях зарплат — \$50 000, \$75 000, \$100 000, \$120 000, \$150 000 и т. д. Это артефакт самоотчёта: респонденты склонны округлять свой доход до ближайших 5, 10 или 25 тысяч долларов. Дополнительный эффект даёт конвертация зарплат из локальных валют: округлённые значения в национальных валютах при переводе в USD формируют вторичные кластеры. При этом логарифмическая шкала (в) и ECDF (г) визуально «сглаживают» этот эффект, показывая, что общее распределение близко к лог-нормальному с медианой около \$65 000.

3.6.2 Проверка закона Бенфорда

Для количественной оценки качества заявленных данных был проведён анализ распределения цифр в значениях годового дохода, основанный на законе Бенфорда [16]. Данный закон гласит, что в естественных числовых данных, охватывающих несколько порядков величин, первые цифры распределены не равномерно, а следуют логарифмическому закону:

$$P(d) = \log_{10}\left(1 + \frac{1}{d}\right), \quad d \in \{1, \dots, 9\}.$$

Аналогично для первых двух цифр ($d \in \{10, \dots, 99\}$). Отклонение от закона Бенфорда может служить индикатором искусственно сфабрикованных или систематически искажённых данных.

На Рисунке 3.12 представлено распределение первой цифры годового дохода: наблюдаемые частоты хорошо согласуются с теоретическими зна-




Рис. 3.11: Детальный анализ распределения годового дохода: (а) общая гистограмма с 500 бинов, (б) зум 0–200k с отметкой «круглых» значений, (в) логарифмическая шкала, (г) эмпирическая функция распределения (ECDF)

чениями закона Бенфорда, что подтверждает естественный характер данных.




Рис. 3.12: Распределение первой цифры годового дохода по сравнению с законом Бенфорда

Более детальный анализ по первым двум цифрам (Рисунок 3.13) также демонстрирует хорошее соответствие теоретическому распределению, однако заметны локальные всплески на значениях, соответствующих «круглым» зарплатным уровням (например, 10, 12, 15, 20, 25, 50, 75, 10 как начало чисел \$10k/\$100k и т. п.).




Рис. 3.13: Распределение первых двух цифр годового дохода по сравнению с законом Бенфорда

Для последних двух цифр закон Бенфорда не применяется: в естественных непрерывных данных последние цифры должны распределяться при-

близительно равномерно (по 1% на каждое значение от 00 до 99). На Рисунке 3.14 видно резкое отклонение от равномерности: наблюдаются аномально высокие пики на значениях 00 и 50, а также повышенные значения для чисел, оканчивающихся на 0 (10, 20, 30 и т. д.). Это напрямую подтверждает эффект округления, обсуждавшийся ранее при анализе «зубцов» — респонденты массово указывают зарплаты, кратные \$100, \$500 или \$1 000.




Рис. 3.14: Распределение последних двух цифр годового дохода (ожидается равномерное распределение 1%)

Проверка по закону Бенфорда даёт двойственную картину. Тест по первым цифрам не выявляет аномалий — массив зарплат имеет естественное происхождение. Однако самоотчётный характер данных порождает систематическое округление, заметное и в зубчатости гистограмм, и в отклонении последних цифр от равномерного распределения.

Фильтрация по 5-му и 95-му перцентилям сужает диапазон до \$3 500–\$210 000 и оставляет 21 122 записи; на них среднее составляет \$74 114, медиана — \$65 122, стандартное отклонение — \$48 497. Отсечение крайних перцентилей убирает ошибочные и нетипичные доходы, сохраняя 90% распределения.

3.6.3 Доход по странам

Медианный доход существенно различается по странам (Рисунок 3.15). Наибольшая медиана наблюдается в США (\$143 000), Швейцарии (\$111 417), Израиле (\$113 334) и Австралии (\$95 466). В Индии медианный доход составляет \$16 749, в России — \$26 891, на Украине — \$26 904. Данный разброс отражает различия в паритете покупательной способности и структуре ИТ-рынков.




Рис. 3.15: Медианный годовой доход по странам

Для визуального сопоставления географии уровней дохода на Рисунке 3.16 приведена компаньон-карта-хороплет, построенная на тех же данных. Цветовая шкала отражает величину медианной зарплаты (шкала ограничена 95-м перцентилем, чтобы экстремальное значение США не «пережигало» палитру). Карта наглядно демонстрирует, что высокие уровни

дохода сосредоточены в Северной Америке, Западной Европе, Австралии, Израиле и Сингапуре, в то время как Восточная Европа, Латинская Америка, Южная и Юго-Восточная Азия находятся в более низком ценовом диапазоне.




Рис. 3.16: Географическое распределение медианной годовой зарплаты разработчиков (хороплет)

3.6.4 Доход по опыту работы

Зависимость дохода от профессионального стажа (`WorkExp`) имеет монотонно возрастающий характер (Рисунок 3.17): медиана растёт от \$14 285 для стажа менее 1 года до \$110 000 для стажа 30+ лет. Наиболее резкий прирост наблюдается в диапазоне 1–10 лет — медиана увеличивается более чем в 2 раза (с \$26 852 до \$61 447).

3.6.5 Доход по технологиям

Медианный доход зависит от используемого технологического стека. Среди языков программирования абсолютными лидерами по медианному доходу являются нишевые и функциональные языки (Erlang, Clojure,




Рис. 3.17: Медианный доход по группам профессионального стажа

Elixir, Ruby). Среди наиболее популярных технологий самую высокую медиану демонстрирует Bash/Shell (\$75 184), что связано с тем, что этот инструмент используется преимущественно опытными DevOps-инженерами. Python (\$67 214), TypeScript (\$65 907) и C# (\$66 151) имеют сопоставимые медианы. Полное распределение представлено на Рисунке 3.18.

Среди баз данных наибольшую медиану показывают Snowflake (\$110 000), DynamoDB (\$82 000) и Cosmos DB (\$80 555) — технологии, характерные для облачных enterprise-решений (Рисунок 3.19).

3.6.6 Совместный анализ популярности и дохода

Столбчатые диаграммы Рисунков 3.18 и 3.19 позволяют сравнивать технологии только по уровню дохода, не учитывая их распространённости. Для одновременного отображения обеих характеристик на Рисунках 3.20 и 3.21 построены пузырьковые диаграммы: горизонтальная ось — популярность технологии (число респондентов, указавших работу с ней), вертикальная ось — медианная зарплата, размер пузырька пропорционален числу респондентов с валидным значением дохода.




Рис. 3.18: Медианный доход по языкам программирования (топ-20)




Рис. 3.19: Медианный доход по базам данных (топ-20)

Такое представление позволяет выделить четыре качественно различных квадранта: (i) массовые языки с умеренным доходом (JavaScript, HTML/CSS, Python, SQL, Java — правая нижняя часть графика); (ii) массовые язы-




Рис. 3.20: Языки программирования: совместное распределение популярности и медианного дохода

ки с повышенным доходом (TypeScript, C#, Bash/Shell); (iii) нишевые, но высокооплачиваемые технологии (Rust, Go, Scala, Ruby — левая верхняя часть); (iv) нишевые языки без существенной зарплатной премии. Аналогичная картина наблюдается для баз данных (Рисунок 3.21): PostgreSQL и MySQL лидируют по распространённости, тогда как Snowflake, DynamoDB и BigQuery формируют нишевой сегмент с самыми высокими медианами.

3.7 Предварительная обработка данных

Для подготовки данных к визуализации в Yandex DataLens были выполнены следующие шаги с использованием Python и библиотеки pandas [10]:

- 1 **Фильтрация выбросов:** значения `ConvertedCompYearly` ниже 5-го перцентиля (\$3 497) и выше 95-го перцентиля (\$210 000) были исключены, что позволило удалить ошибочно введённые данные и нетипичные доходы.




Рис. 3.21: Базы данных: совместное распределение популярности и медианного дохода

- 2 **Обработка пропусков:** записи без указания дохода (64,19%) исключались из расчётов агрегированных зарплатных метрик, но сохранялись для анализа технологического ландшафта.
- 3 **Разделение мульти-ответов:** колонки с множественным выбором (например, LanguageHaveWorkedWith) содержат значения, разделённые символом «;». Для корректного подсчёта была применена процедура `split` с последующей группировкой по отдельным значениям.
- 4 **Группировка по стажу:** значения WorkExp были разбиты на категориальные группы: <1, 1–3, 3–5, 5–10, 10–15, 15–20, 20–30, 30+ лет.
- 5 **Агрегация метрик:** для каждого сочетания «технология × страна» и «технология × группа стажа» были рассчитаны медианный и средний доход, а также количество респондентов.

3.8 Концепция дашборда (wireframe)

На основе проведённого EDA была спроектирована структура интерактивного дашборда для Yandex DataLens. Дашборд состоит из следующих блоков:

- 1 **Фильтры (верхняя панель):** страна, тип разработчика, диапазон стажа, язык программирования — позволяют динамически ограничивать выборку.
- 2 **Карточки ключевых метрик:** общее количество респондентов, медианный доход, доля использующих AI-инструменты.
- 3 **Основная область визуализации:**
 - Столбчатая диаграмма медианного дохода по странам (с возможностью переключения на технологии).
 - Тепловая карта «язык программирования × группа стажа → медианный доход».
 - Линейный график зависимости дохода от стажа.
 - Столбчатая диаграмма популярности технологий (с возможностью переключения между «используют» и «хотят изучить»).
- 4 **Детализация:** таблица с агрегированными данными, позволяющая экспортировать результаты в CSV.

Эскиз дашборда представлен на Рисунке [3.22](#).




Рис. 3.22: Wireframe дашборда в Yandex DataLens

4 Обзор источников

4.1 Методологические особенности набора данных

Интерпретируя результаты, нужно помнить об ограничениях сбора данных. Респондентов набирают в основном через каналы самого Stack Overflow, ответы проходят квалифицирующие вопросы и фильтрацию, а доход приводится к USD по фиксированному курсу на выбранную дату [5]. Отсюда два следствия: выборка смещена в сторону наиболее вовлечённых пользо-

вателей платформы, а межстрановое сравнение компенсаций требует осторожности.

4.2 Академические исследования и аналитика на основе опроса

Stack Overflow публикует результаты опросов ежегодно, поэтому по ним можно проследить динамику индустрии за много лет: например, выпуск 2016 года [6] фиксирует ранние этапы формирования нынешнего набора технологий. На этих же данных строятся и прикладные инструменты: первый калькулятор зарплат разработчиков был создан Джулией Силге (Julia Silge) ещё в 2017 году [7]. Это ранний пример того, как открытые данные опроса используются для оценки рыночной стоимости компетенций.

В академической среде данные опросов также находят широкое применение. В работе A. Prakash и I. S. Yadav анализируются гендерные различия в оплате труда среди разработчиков на межстрановой выборке; авторы применяют квантильную регрессию и декомпозицию Оаксаки—Блиндера для оценки эффектов «glass ceiling» и «sticky floor» [8]. Этот результат показывает, что данные опроса могут использоваться не только для описательной статистики, но и для причинно-ориентированного анализа структурных барьеров.

Другой пример использования расширенных переменных опроса представлен в исследовании P. Verma и соавторов: авторы анализируют ответы 2022 года и сравнивают опыт нейроотличных и нейротипичных инженеров, выделяя различия в рабочих практиках и возникающих трудностях [9].

5 Заключение

В рамках курсовой работы был проведён разведочный анализ набора данных Stack Overflow Annual Developer Survey 2024 и разработан интерактивный дашборд в Yandex DataLens, позволяющий исследовать факторы, влияющие на компенсацию IT-специалистов на глобальном рынке труда. В данном разделе представлены результаты выполнения поставленных задач, описание разработанного дашборда, ответ на основной исследовательский вопрос и ограничения работы.

5.1 Описание выполненных задач

В ходе выполнения курсовой работы реализованы все исследовательские и программные задачи, поставленные на начальном этапе:

- Проведён разведочный анализ набора данных Stack Overflow Annual Developer Survey 2024 (Глава 3). Результаты включают описание структуры данных и анализ пропусков, географический и демографический профиль респондентов, обзор технологического ландшафта и распределения годового дохода.
- Подготовлен обзор источников, использующих данные ежегодных опросов Stack Overflow (Глава 4).
- Спроектирован макет (wireframe) интерактивного дашборда (Рисунок 3.22); вариант согласован с научным руководителем до начала реализации.
- Выполнена очистка и подготовка данных: фильтрация выбросов годового дохода по 5-му и 95-му перцентилям, обработка пропусков, агрегация по странам, языкам программирования и группам стажа

работы. Подготовленные таблицы экспортированы в формат CSV для загрузки в Yandex DataLens.

- Пройден курс «DataLens: анализ и визуализация данных» от Яндекс Практикума. Свидетельство о прохождении приведено в конце раздела.
- Реализован интерактивный дашборд в Yandex DataLens. Публичная ссылка: <https://datalens.yandex/8nv6m7mu0cd0s>. Детальное описание дашборда приведено в разделе 5.3.
- Создан публичный [GitHub-репозиторий](#) с исходным кодом, ноутбуками, графиками разведочного анализа и подготовленными данными.

5.2 Описание структуры Git-репозитория

Исходный код, ноутбуки и подготовленные данные размещены в публичном репозитории на GitHub по адресу <https://github.com/Soyava/course-project-stackoverflow-survey>. Структура репозитория следующая:

- `notebooks/` — Jupyter-ноутбуки, организованные по принципу «один файл — одна задача»: ноутбуки разведочного анализа данных и подготовки CSV-файлов для дашборда;
- `data_processed/` — агрегированные CSV-файлы, загружаемые в Yandex DataLens;
- `figures/eda_images/` — графики разведочного анализа в формате PNG;
- `README.md` — описание, ссылки на источники данных и интерактивный дашборд.

5.3 Описание интерактивной визуализации

Интерактивный дашборд реализован на платформе Yandex DataLens и опубликован для свободного доступа по ссылке: <https://datalens.yandex/8nv6m7mu0cd0s>. Общий вид дашборда представлен на Рисунке 5.1.




Рис. 5.1: Общий вид разработанного дашборда в Yandex DataLens

Дашборд состоит из следующих блоков (сверху вниз):

- три глобальных фильтра в верхней части: страна, тип разработчика, группа стажа работы;
- блок ключевых показателей: общее число респондентов (65 437), медианный годовой доход (\$65 152), доля разработчиков, использующих AI-инструменты в работе (61,8 %);
- горизонтальная гистограмма медианного годового дохода по странам с наибольшим числом респондентов;
- сводная таблица в виде тепловой карты: язык программирования × группа профессионального стажа, оттенок ячейки соответствует медианному годовому доходу для соответствующей комбинации;

- столбчатая диаграмма медианного годового дохода по группам стажа работы (от 00–01 до 30+ лет);
- гистограмма популярности языков программирования по числу пользователей;
- агрегированная таблица детализации в нижней части дашборда: страна × язык × стаж с медианным доходом и числом респондентов в каждом срезе.

По сравнению с макетом (Рисунок 3.22) в итоговой реализации график медианного дохода по стажу работы выполнен в виде столбчатой диаграммы вместо линейного, а отдельный фильтр по языку программирования не вошёл в финальную версию: связанные с этим фильтром перестроения тепловой карты приводили к нечитаемому результату из-за конфликта связей между базами данных, поэтому от него было решено отказаться.

5.4 Ответ на основной вопрос работы

Цель работы заключалась в выявлении ключевых факторов ценообразования на глобальном рынке труда в IT-сфере. По результатам разведочного анализа и построенного дашборда можно выделить три основных фактора, определяющих уровень компенсации разработчиков.

География. Страна занятости остаётся доминирующим фактором: медианный годовой доход в США превышает \$130 000, в Швейцарии и Дании — около \$90–110 000, тогда как для Индии этот показатель составляет менее \$25 000. Разрыв между странами на верхних и нижних позициях рейтинга достигает 5–7 раз и существенно превосходит влияние всех остальных факторов, рассмотренных в работе.

Профессиональный опыт. Медианный годовой доход монотонно возрастает с увеличением стажа: от примерно \$20 000 для начинающих раз-

работчиков (00–01 лет) до примерно \$110 000 для специалистов с опытом 30+ лет. Наибольший относительный прирост приходится на первые 5–10 лет карьеры, после чего темп роста существенно замедляется.

Технологический стек. Тепловая карта «язык программирования × группа стажа» показывает, что при сопоставимом опыте языки заметно различаются по медианной компенсации: Haskell, Go и Bash/Shell оплачиваются выше массовых универсальных языков.

Опрос 2024 года выявил и эффект, не заложенный в исходную постановку задачи, — масштаб распространения AI-инструментов: об их использовании в работе сообщают 61,8 % респондентов. Для индустрии это сравнительно недавнее, но уже массовое изменение.

Каждый из перечисленных факторов и их сочетания можно изучить в построенном дашборде через встроенные фильтры.

Дашборд ориентирован прежде всего на начинающих IT-специалистов. Фильтры по стране, типу разработчика и стажу показывают медианную компенсацию в интересующем сегменте, а тепловая карта «язык программирования × стаж» помогает увидеть наиболее прибыльные сочетания технологий и обоснованно выбрать направление развития.

5.5 Ограничения работы

В ходе исследования были выявлены следующие объективные ограничения, влияющие на интерпретацию полученных результатов.

Особенности выборки. Stack Overflow — англоязычная платформа, поэтому страны с меньшим распространением английского языка могут быть недопредставлены в выборке. Для таких стран, а также для стран с малым числом ответивших, оценки медианного дохода имеют большую погрешность.

Пропуски в целевой переменной. Поле `ConvertedCompYearly` за-

полнено приблизительно для 36 % респондентов. Все выводы о зарплатах построены на этой подвыборке, что в первую очередь сказывается на надёжности оценок по странам с малым числом ответивших.

Самоотчётный характер данных. Размер годового дохода указывается респондентами самостоятельно и не верифицируется. Анализ распределения дохода выявил характерный «пилообразный» паттерн, связанный с округлением респондентами своих ответов до «круглых» сумм, что подтверждается также проверкой по закону Бенфорда (раздел 3.6).

Срез данных. В работе используется выборка только за 2024 год, поэтому динамика рынка во времени, в том числе эффект массового распространения AI-инструментов, в исследовании не рассматривается.

Приложение. Свидетельство об успешном прохождении курса «DataLens: анализ и визуализация данных» доступно по ссылке: <https://disk.360.yandex.ru/i/AmJ7f4NaoTTSRA>.

6 Описание применения генеративной модели

В ходе выполнения курсовой работы для решения вспомогательных задач использовалось семейство генеративных моделей Claude от компании Anthropic. Доступ к моделям осуществлялся через веб-интерфейс <https://claude.ai>.

Модели применялись для двух типов задач:

- **Помощь в фильтрации и очистке данных.** Обсуждение подходов к подготовке набора данных Stack Overflow Annual Developer Survey 2024: выбор порогов для отсека выбросов годового дохода (перцентильная фильтрация), обработка пропусков в ключевых полях, нормализация полей с мульти-ответами (языки программирования, базы данных, инструменты).
- **Планирование и изучение использованных методов работы с данными.** Обсуждение применимости различных техник разведочного анализа к конкретным исследовательским вопросам, подбор подходящих типов визуализаций под характер данных, ознакомление с особенностями используемых библиотек Python (pandas, matplotlib и др.).

Сгенерированные моделью фрагменты кода и предложенные формулировки подвергались ручной проверке и адаптации под задачи работы. Итоговые выводы и интерпретация результатов выполнены автором самостоятельно.

Список литературы

1. Stack Overflow. — Текст : электронный // Wikipedia : [сайт]. — URL: https://en.wikipedia.org/wiki/Stack_Overflow (дата обращения: 23.01.2026).
2. Что такое Yandex DataLens. — Текст : электронный // Yandex Cloud : [сайт]. — URL: <https://yandex.cloud/ru/docs/datalens/concepts/> (дата обращения: 13.12.2025).
3. Stack Overflow Annual Developer Survey. — Текст : электронный // Stack Overflow : [сайт]. — URL: <https://survey.stackoverflow.co> (дата обращения: 24.01.2026).
4. 2024 Developer Survey. — Текст : электронный // Stack Overflow : [сайт]. — URL: <https://survey.stackoverflow.co/2024/> (дата обращения: 13.12.2025).
5. Methodology | 2024 Stack Overflow Developer Survey. — Текст : электронный // Stack Overflow : [сайт]. — URL: <https://survey.stackoverflow.co/2024/methodology> (дата обращения: 01.02.2026).
6. Stack Overflow Developer Survey 2016 Results. — Текст : электронный // Stack Overflow : [сайт]. — URL: <https://survey.stackoverflow.co/2016> (дата обращения: 01.02.2026).
7. Silge J. How Much Do Developers Earn? Find Out with the Stack Overflow Salary Calculator. — 2017. — Текст : электронный // Stack Overflow Blog : [сайт]. — URL: <https://stackoverflow.blog/2017/09/19/much-developers-earn-find-stack-overflow-salary-calculator/> (дата обращения: 01.02.2026).

8. Prakash A., Yadav I. S. Analysing gender pay disparities and structural barriers among software developers: a cross-country study // Journal for Labour Market Research. — 2025. — Vol. 59. — Art. 17. — DOI: 10.1186/s12651-025-00407-z (дата обращения: 01.02.2026).
9. Verma P., Cruz M. V., Liebel G. Differences between Neurodivergent and Neurotypical Software Engineers: Analyzing the 2022 Stack Overflow Survey. — arXiv:2506.03840. — 2025. — Текст : электронный (дата обращения: 01.02.2026).
10. pandas documentation. — Текст : электронный // pandas : [сайт]. — URL: <https://pandas.pydata.org/docs/> (дата обращения: 14.12.2025).
11. NumPy Documentation. — Текст : электронный // NumPy : [сайт]. — URL: <https://numpy.org/doc/stable/> (дата обращения: 14.12.2025).
12. Matplotlib documentation. — Текст : электронный // Matplotlib : [сайт]. — URL: <https://matplotlib.org/stable/> (дата обращения: 14.12.2025).
13. Baltes S., Park G., Serebrenik A. Is 40 the New 60? How Popular Media Portrays the Employability of Older Software Developers // IEEE Software. — 2020. — Vol. 37, no. 6. — P. 26–31. — DOI: 10.1109/MS.2020.3014178.
14. Рабочая сила, занятость и безработица в России (по результатам выборочных обследований рабочей силы). 2024: Стат. сб. / Росстат. — М., 2024. — Табл. 2.32.
15. Datawrapper: Create charts, maps, and tables. — URL: <https://www.datawrapper.de> (дата обращения: 18.04.2026).
16. Benford F. The law of anomalous numbers // Proceedings of the American philosophical society. — 1938. — Vol. 78, no. 4. — P. 551–572.